



第二讲

重整化群与深度学习

尤亦庄
(加州大学圣地亚哥分校)

集智因果涌现读书会

2021夏

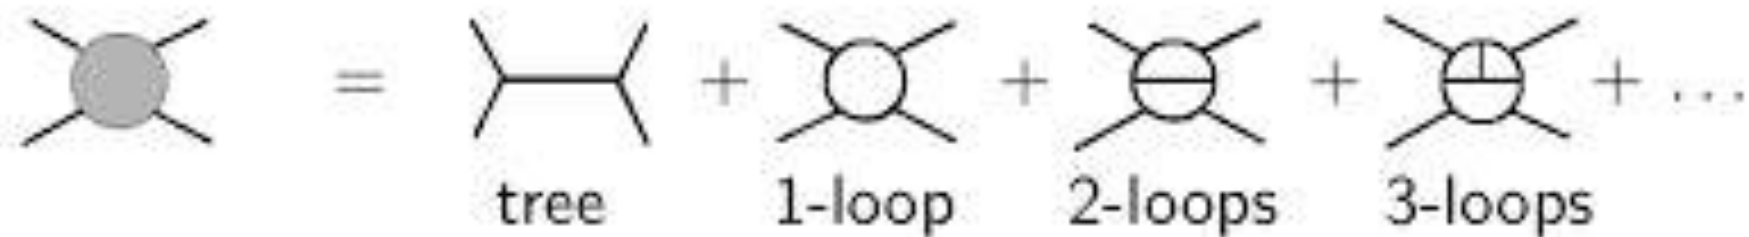
什么是重整化？

- 早期的黑历史(1950-1970s)

重整化是试图挽救量子场论圈图发散的奇怪的数学技巧

Perturbation expansion in quantum field theory:

Amplitude = sum of Feynman diagrams



The diagram shows a shaded circle with four external lines, representing a full amplitude. This is equated to a sum of Feynman diagrams: a tree-level diagram (two vertices connected by a horizontal line), a 1-loop diagram (a circle with two external lines), a 2-loops diagram (a circle with a horizontal line through it and two external lines), and a 3-loops diagram (a circle with a vertical line through it and two external lines). The diagrams are labeled 'tree', '1-loop', '2-loops', and '3-loops' respectively, with an ellipsis indicating further terms in the series.

- 一个(过度简化)的类比：

$$1 + 2 + 3 + 4 + 5 + \dots = -\frac{1}{12} \quad ?!$$

知乎

首页 会员 发现 等你来答

为什么自然数的和等于 $-1/12$?

欧拉是如何证明出来的? 显示全部

关注者
786

被浏览
713,070



返朴

返朴，努力做好科普！微信...

关注问题

写回答

邀请回答

好问题 109

15 条评论

科普 话题的优秀答主

什么是重整化?

$$1 + 2 + 3 + 4 + 5 + \dots = -\frac{1}{12}$$

● 暴力(错误)的打开方式

$$\begin{aligned}
 c &= 1 + 2 + 3 + 4 + 5 + 6 + \dots \\
 4c &= \quad \quad 4 \quad \quad \quad + 8 \quad \quad \quad + 12 + \dots \\
 -3c = c - 4c &= 1 - 2 + 3 - 4 + 5 - 6 + \dots \\
 &\stackrel{x=1}{=} 1 - 2x + 3x^2 - 4x^3 + 5x^4 - 6x^5 + \dots \\
 &= (1+x)^{-2} \\
 &\stackrel{x=1}{=} \frac{1}{4} \\
 \text{SO } c &= -\frac{1}{12}
 \end{aligned}$$

Another way of finding the constant is as follows - 46

Let us take the series $1+2+3+4+5+\dots$. Let C be its constant. Then $C = 1+2+3+4+\dots$

$\therefore 4C = 4 + 8 + \dots$

$\therefore -3C = 1-2+3-4+\dots = \frac{1}{(1+1)^2} = \frac{1}{4}$

$\therefore C = -\frac{1}{12}$



S. Ramanujan(1931)


什么是重整化?

$$1 + 2 + 3 + 4 + 5 + \cdots = -\frac{1}{12}$$


● 重整化(正确)的打开方式

引入截断标度 N : $\sum_{n=1}^{\infty} n e^{-n/N} \xrightarrow{N \rightarrow \infty} \sum_{n=1}^{\infty} n$


$N = 5$



$N = 20$



$N = 1000$



$$\sum_{n=1}^{\infty} n e^{-n/N} = \frac{1}{2(\cosh \frac{1}{N} + 1)} = N^2 - \frac{1}{12} + \frac{1}{240N^2} + \mathcal{O}(\frac{1}{N^4})$$



陶哲轩
(2010博客)

什么是重整化?

$$1 + 2 + 3 + 4 + 5 + \cdots = -\frac{1}{12}$$

● 重整化(正确)的打开方式

任意的重整化方案

引入截断标度 N : $\sum_{n=1}^{\infty} n \eta(n/N) \xrightarrow{N \rightarrow \infty} \sum_{n=1}^{\infty} n$



陶哲轩
(2010博客)

$$\begin{aligned} \sum_{n=1}^{\infty} n e^{-n/N} &= N^2 - \frac{1}{12} + \frac{1}{240N^2} + \mathcal{O}\left(\frac{1}{N^4}\right) \\ \sum_{n=1}^{\infty} \frac{n}{((n/N)^2 + 1)^2} &= \frac{N^2}{2} - \frac{1}{12} - \frac{1}{60N^2} + \mathcal{O}\left(\frac{1}{N^4}\right) \\ \sum_{n=1}^{\infty} \frac{n}{(n/N)^4 + 1} &= \frac{\pi N^2}{4} - \frac{1}{12} + \mathcal{O}\left(\frac{1}{N^4}\right) \end{aligned}$$

与重整化方案无关的普适常数

什么是重整化？


- 为什么需要重整化？ - 我们认识世界的能力是有限的
- 太远的地方我们看不到

$1 + 2 + 3 + 4 + 5 + \dots + 1000 + 1001 + \dots$

近处 远处...

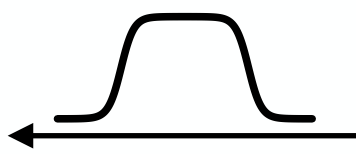
- 太小的结构我们看不清
- 太大的结构我们看不全
- 如何以有限的信息处理能力，试图理解无限信息量的世界？
- 策略：躺平放弃

- 截断信息
 - 改变标度
- } 重整化



什么是重整化？

- 现代化的理解(1970s-)
- Wilson: 动量空间重整化
 - 截断高动量模式

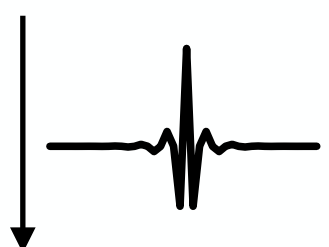
$$\phi(k) \rightarrow \phi(k)\eta(k/\Lambda)$$



重整化方案 η
(卷积核)



K.G. Wilson

- Kadanoff: 实空间重整化
 - 粗粒化细节结构

$$\tilde{\phi}(r) \rightarrow (\tilde{\eta} \star \tilde{\phi})(r) = \int_{r'} \tilde{\phi}(r - r') \tilde{\eta}(r'/R)$$




L.P. Kadanoff

- 两者等价性：傅立叶变换下
 - 大动量结构 = 小尺度结构
 - 动量空间乘积 = 实空间卷积 (脑洞：卷积神经网络...)

什么是重整化？

- 重整化方法的未来(2014-): 机器学习重整化
(以机器而不是人来设计重整化方案)

arXiv:1410.3831 (stat)

[Submitted on 14 Oct 2014]

An exact mapping between the Variational Renormalization Group and Deep Learning

Pankaj Mehta, David J. Schwab

arXiv:1704.06279 (cond-mat)

[Submitted on 20 Apr 2017 (v1), last revised 24 Sep 2018 (this version, v2)]

Mutual Information, Neural Networks and the Renormalization Group

arXiv:1802.02840 (cond-mat)

Maciej Koch-Janusz, Zohar Ringel

[Submitted on 8 Feb 2018 (v1), last revised 19 Dec 2018 (this version, v4)]

Neural Network Renormalization Group

Shuo-Hui Li, Lei Wang

arXiv:1903.00804 (cond-mat)

[Submitted on 3 Mar 2019 (v1), last revised 29 Aug 2019 (this version, v3)]

Machine Learning Holographic Mapping by Neural Network Renormalization Group

Hong-Ye Hu, Shuo-Hui Li, Lei Wang, Yi-Zhuang You

arXiv:2010.00029 (cs)

[Submitted on 30 Sep 2020 (v1), last revised 18 Dec 2020 (this version, v4)]

RG-Flow: A hierarchical and explainable flow model based on renormalization group and sparse prior

Hong-Ye Hu, Dian Wu, Yi-Zhuang You, Bruno Olshausen, Yubel Chen

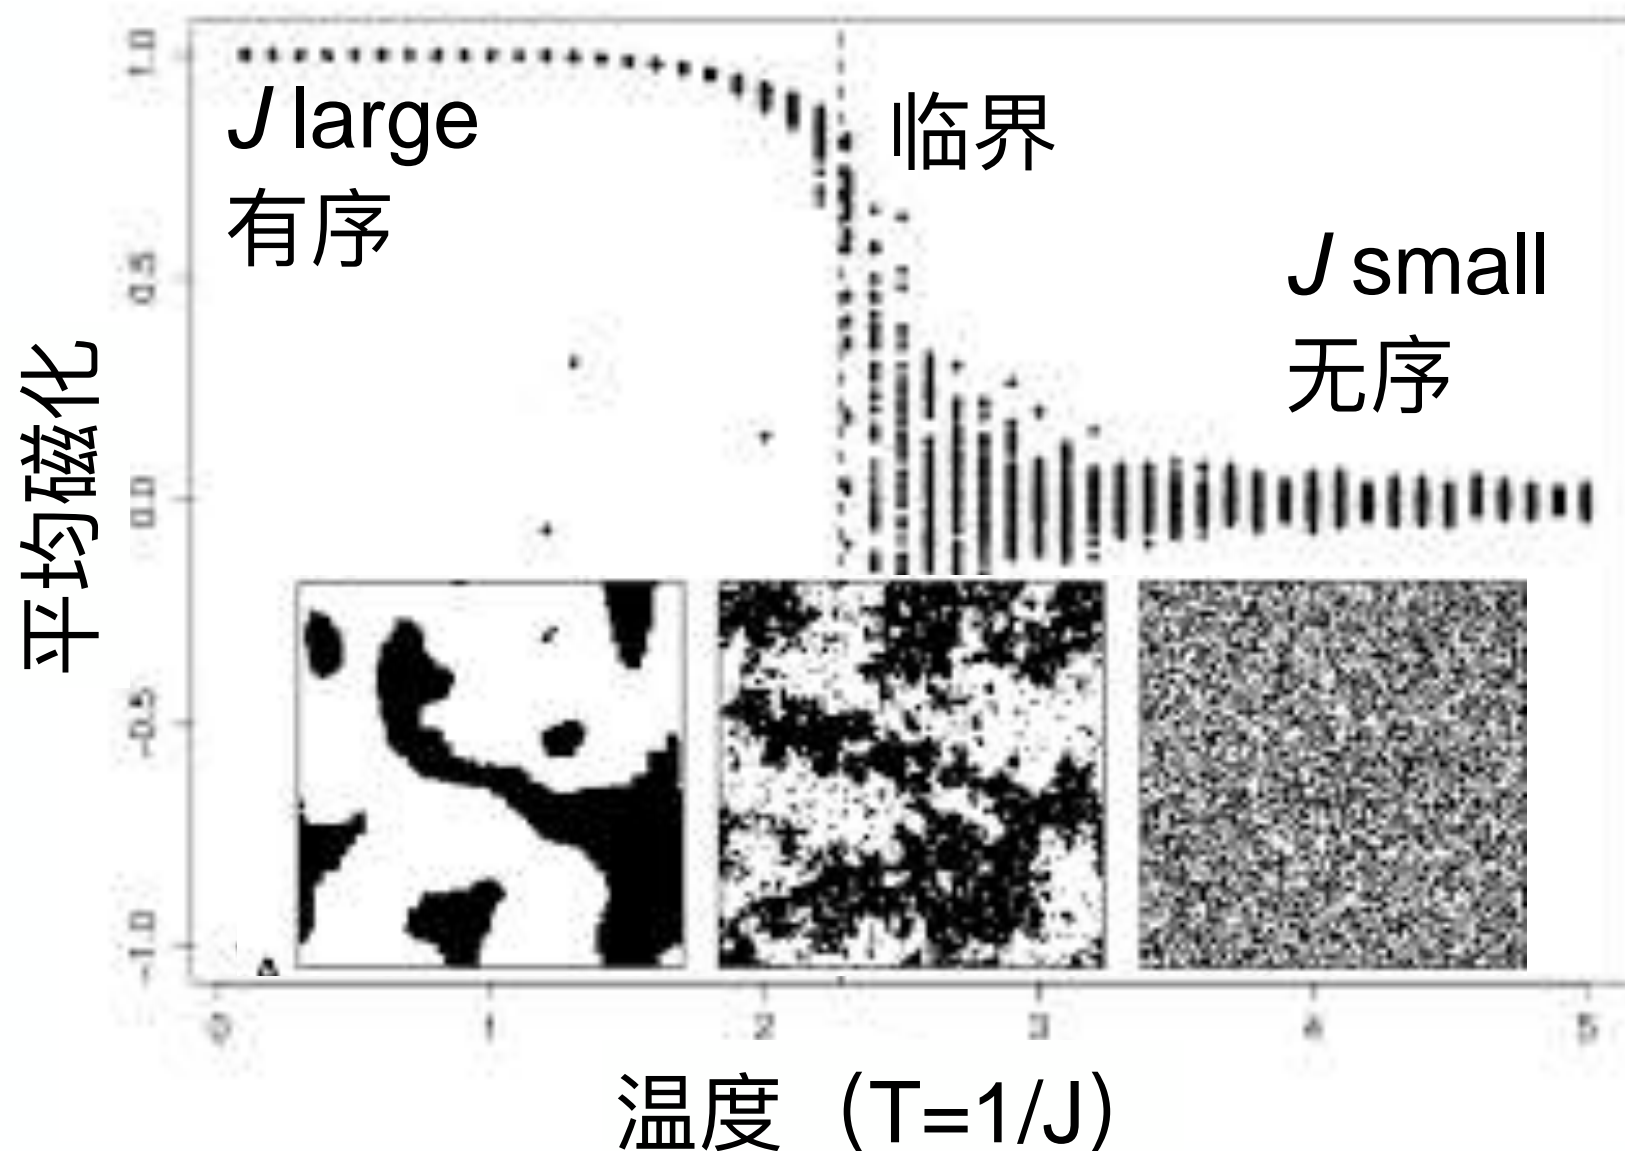

Ising模型重整化

● 2D Ising模型


$$H(\boldsymbol{\sigma}) = -J \sum_{\langle ij \rangle} \sigma_i \sigma_j$$

能量函数

Ising自旋
 $\sigma_i = \pm 1$



临界：分形，无标度



Ising模型重整化

- 概率模型 (Boltzmann概率)


$$P(\boldsymbol{\sigma}) = \frac{1}{Z} e^{-H(\boldsymbol{\sigma})}$$

概率分布

$$Z = \sum_{\boldsymbol{\sigma}} e^{-H(\boldsymbol{\sigma})}$$

配分函数

$$= \frac{1}{Z} e^{J \sum_{\langle ij \rangle} \sigma_i \sigma_j} = \frac{1}{Z} \prod_{\langle ij \rangle} e^{J \sigma_i \sigma_j}$$



- 实空间重整化

- 第一步：块划分 (2x2 角共享块)

$$P(\boldsymbol{\sigma}) \propto P(\sigma_0, \sigma_1, \sigma_6, \sigma_7) P(\sigma_2, \sigma_3, \sigma_8, \sigma_9) \cdots$$

$$P(\sigma_7, \sigma_8, \sigma_{13}, \sigma_{14}) \cdots$$


概率：乘法原理

$$H(\boldsymbol{\sigma}) = H(\sigma_0, \sigma_1, \sigma_6, \sigma_7) + H(\sigma_2, \sigma_3, \sigma_8, \sigma_9) \cdots$$

$$+ H(\sigma_7, \sigma_8, \sigma_{13}, \sigma_{14}) \cdots$$

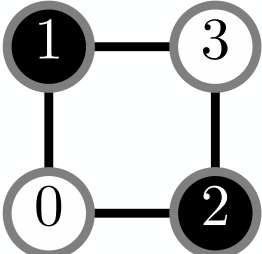
能量：加法原理

$$-J(\sigma_0\sigma_1 + \sigma_6\sigma_7 + \sigma_0\sigma_6 + \sigma_1\sigma_7)$$




Ising模型重整化

- 实空间重整化
- 第二步：隐变量涌现 (表象学习)


$$H_{\text{loc}}(\boldsymbol{\sigma}) = -J(\sigma_0\sigma_1 + \sigma_2\sigma_3 + \sigma_0\sigma_2 + \sigma_1\sigma_3)$$
$$P_{\text{loc}}(\boldsymbol{\sigma}) = Z_{\text{loc}}^{-1} e^{-H_{\text{loc}}(\boldsymbol{\sigma})}$$

- 这里可以选择任何具有表象学习能力的生成型模型
- Restricted Boltzmann Machine (RBM)


$$H_{\text{RBM}}(\boldsymbol{\sigma}, \boldsymbol{\tau}) = - \sum_{i,j} w_{ij} \sigma_i \tau_j$$
$$P_{\text{RBM}}(\boldsymbol{\sigma}) = Z_{\text{RBM}}^{-1} \sum_{\boldsymbol{\tau}} e^{-H_{\text{RBM}}(\boldsymbol{\sigma}, \boldsymbol{\tau})}$$



- 优化目标：最小化 $D_{\text{KL}}(P_{\text{loc}} || P_{\text{RBM}})$
- 优化变量：RBM权重 w_{ij}



Ising模型重整化

- 实空间重整化
- 第二步：隐变量涌现 (表象学习)




- 通过训练RBM, 发现最优解为 $\forall i, j : w_{ij} = w(J)$
- 所有隐变量都学到了一样的特征 \rightarrow 只用一个隐变量就够

$$H_{\text{RBM}}(\boldsymbol{\sigma}, \tau) = -w(J) \sum_i \sigma_i \tau$$



$$H_{\text{loc}}(\boldsymbol{\sigma}) = -J(\sigma_0\sigma_1 + \sigma_2\sigma_3 + \sigma_0\sigma_2 + \sigma_1\sigma_3)$$




Ising模型重整化

- 实空间重整化
 - 第二步：隐变量涌现 (表象学习)
 - 因果涌现


$$P_{\text{loc}}(\boldsymbol{\sigma}) \propto e^{-H_{\text{loc}}(\boldsymbol{\sigma})}$$

$$P_{\text{RBM}}(\boldsymbol{\sigma}, \tau) \propto e^{-H_{\text{RBM}}(\boldsymbol{\sigma}, \tau)}$$

概率模型



(近似)等价




隐变量的涌现


$$P_{\text{loc}}(\boldsymbol{\sigma}) = P(\sigma_0)P(\sigma_1|\sigma_0)P(\sigma_2|\sigma_0)P(\sigma_3|\sigma_1, \sigma_2)$$

$$P_{\text{RBM}}(\boldsymbol{\sigma}, \tau) = P(\tau)P(\sigma_0|\tau)P(\sigma_1|\tau)P(\sigma_2|\tau)P(\sigma_3|\tau)$$

因果模型



不同的因果结构




形式因的涌现

$$\forall i, j : (\sigma_i \perp\!\!\!\perp \sigma_j | \tau)_G$$

Ising模型重整化


- 实空间重整化
- 第三步：显变量边缘化（获取有效模型）



Ising模型重整化


- 实空间重整化

- 第三步：显变量边缘化（获取有效模型）



$$H(\sigma, \tau_1, \tau_2) = -w(J)(\sigma\tau_1 + \sigma\tau_2)$$

$$P(\tau_1, \tau_2) = \frac{1}{Z} \sum_{\sigma} e^{-H(\sigma, \tau_1, \tau_2)}$$
$$\propto \cosh(w(J)(\tau_1 + \tau_2))$$



$$H(\tau_1, \tau_2) = -\ln P(\tau_1, \tau_2)$$


$$= -\ln \cosh(w(J)(\tau_1 + \tau_2))$$

$$= -\frac{1}{2} \ln \cosh(2w(J))\tau_1\tau_2 + \text{const.}$$

$$= -J'\tau_1\tau_2 + \text{const.}$$

Ising模型重整化

- 实空间重整化



$$H(\sigma) = -J \sum_{\langle ij \rangle} \sigma_i \sigma_j \xrightarrow{\text{等效近似}} H(\tau) = -J' \sum_{\langle ij \rangle} \tau_i \tau_j$$

$$J' = \frac{1}{2} \ln \cosh(2w(J)) \quad (\text{重整化方程})$$


- 格点间距扩大 $\sqrt{2}$ 倍

- 耦合常数变化为 $J \rightarrow J'$

↑
方程的一部分可以依靠机器学习
而不需要人来推导一切

Ising模型重整化

- 重整化流 - 模型参数随重整化迭代而跑动



- 重整化不动点

$J = 0$ (无序 - 稳定)

$J \approx 0.486$ (临界 - 非稳)


$J = \infty$ (有序 - 稳定)

2D Ising模型严格解

$$J_c = \frac{1}{2} \ln(1 + \sqrt{2}) \approx 0.4407$$

Ising模型重整化

- 重整化不动点 - 系统在尺度变换下保持不变 (自相似, 无标度)



Douglas Ashton

YouTube

Ising模型重整化

- 标度律与临界指数

- 在不动点附近线性化重整化方程

$$\begin{aligned} J' = \mathcal{R}(J) &\xrightarrow{J', J \rightarrow J_c} (J' - J_c) = \partial_J \mathcal{R}(J_c)(J - J_c) + \dots \\ &= \frac{1}{2} \ln \cosh(2w(J)) \end{aligned}$$


- 经过 n 步迭代

$$\begin{aligned} (J - J_c) &= (\partial_J \mathcal{R}(J_c))^n (J_0 - J_c) \\ \xi &= \xi_0 / (\sqrt{2})^n \quad (\text{关联长度 - 磁畴之特征尺度}) \end{aligned}$$

- 联立方程消去 n

标度律 $\xi \propto (J - J_c)^{-\nu}$

临界指数 $\nu = \frac{\ln \sqrt{2}}{\ln \partial_J \mathcal{R}(J_c)} \approx 1.1$
(严格解 $\nu = 1$)



重整化与生成型模型

- 重整化的一般思路

- 第一步：显变量划分

$$X = X_1 \cup X_2 \cup X_3 \cdots$$

$$P(X) \propto \prod_k P(X_k) \quad (\text{Not disjoint})$$

- 第二步：隐变量涌现


$$P(X_k) \rightarrow P'(X_k) = \sum_{Y_k} P'(X_k, Y_k)$$

$$P(X) \rightarrow P'(X, Y) \propto \prod_k P'(X_k, Y_k)$$

- 第三步：显变量边缘化


$$P'(Y) = \sum_X P'(X, Y)$$

深度生成型模型
(Deep Generative Model)



重整化与生成型模型

- 在Ising模型例子中，表象学习只发现了一个特征（即铁磁模式），这使得隐变量得以继续保持单个Ising变量的形式



- 然而，对于更加一般的系统，未必能够在重整化过程中维持体系的自由度与模型的形式不变（事实上很多复杂系统的集体行为与个体行为的描述是完全不同的）
- 这就要求我们放弃重整化必须保模型形式简洁不变的幻想
- 一般意义的重整化需要依赖不断迭代的机器学习，在不同尺度上发掘新的特征变量并构建新的概率模型

重整化方案的设计原则

- 机器应该如何自动设计重整化方案？重整化的目标是什么？
- 基于信息论的原则

- 最大环境互信息原则（传统重整化）

arXiv:1704.06279 (cond-mat)

[Submitted on 20 Apr 2017 (v1), last revised 24 Sep 2018 (this version, v2)]

Mutual Information, Neural Networks and the Renormalization Group

Maciej Koch-Janusz, Zohar Ringel

- 最小全息互信息原则（全息重整化）

arXiv:1903.00804 (cond-mat)

[Submitted on 3 Mar 2019 (v1), last revised 29 Aug 2019 (this version, v3)]

Machine Learning Holographic Mapping by Neural Network Renormalization Group

Hong-Ye Hu, Shuo-Hui Li, Lei Wang, Yi-Zhuang You


- ...基于因果科学的原则？ ？ ？

最大环境互信息原则

- 通过设计目标函数来指导机器发掘相关(relevant)的隐变量

- 局部目标：最小化KL散度


$$D_{\text{KL}}(P_{\text{loc}} || P_{\text{RBM}})$$



- 环境目标：最大化隐变量与环境显变量的互信息

$$I(\sigma_{\mathcal{E}} : \tau) = \sum_{\tau, \sigma_{\mathcal{E}}} P(\sigma_{\mathcal{E}}, \tau) \ln \frac{P(\sigma_{\mathcal{E}}, \tau)}{P(\tau)P(\sigma_{\mathcal{E}})}$$

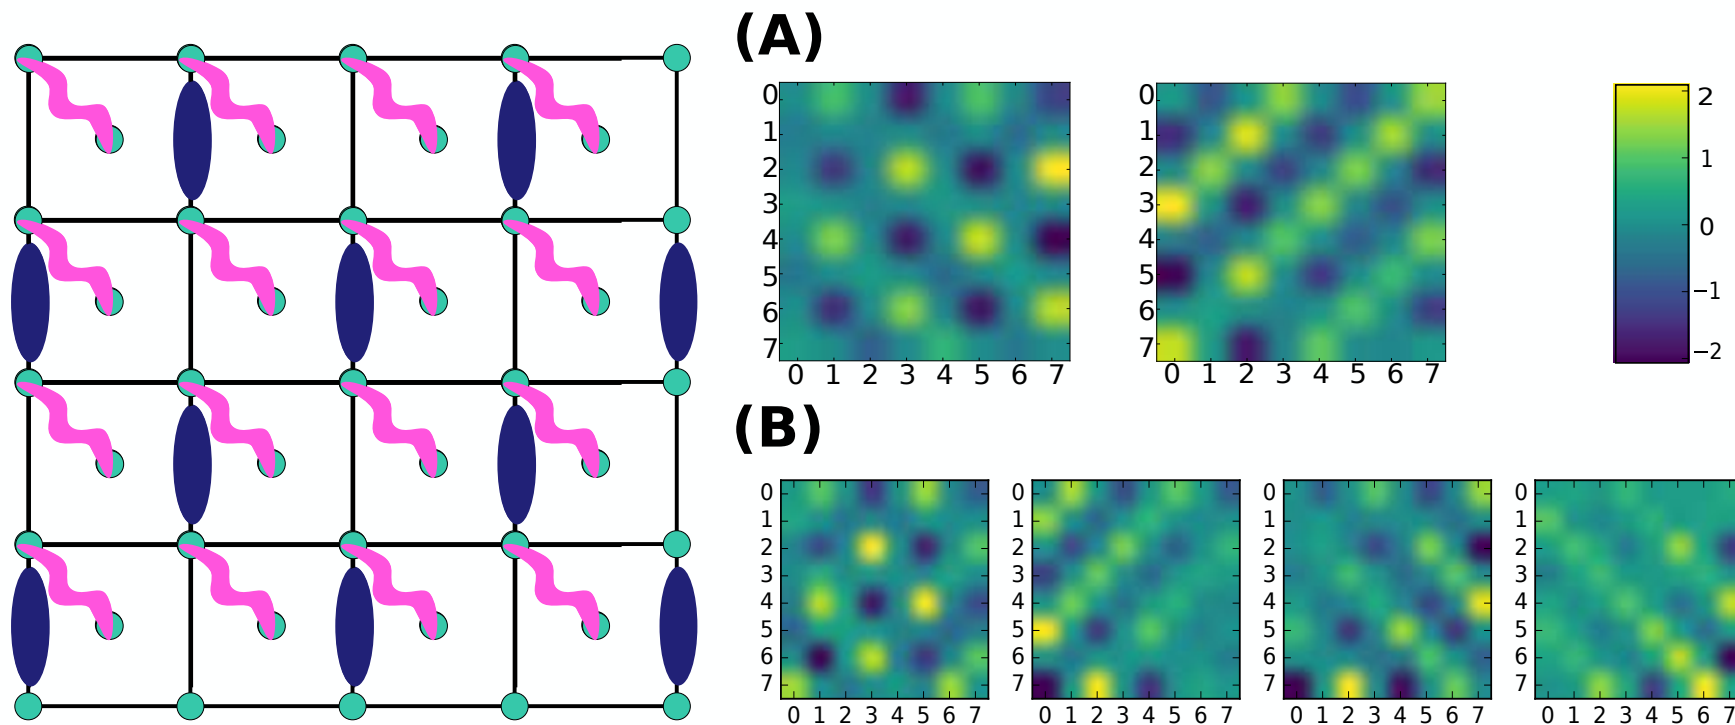
$$P(\sigma, \tau) \propto P_{\text{RBM}}(\sigma_0, \tau) \prod_{k \neq 0} P_{\text{loc}}(\sigma_k)$$



- 总体目标： $\mathcal{L} = D_{\text{KL}}(P_{\text{loc}} || P_{\text{RBM}}) - \beta I(\sigma_{\mathcal{E}} : \tau)$

最大环境互信息原则

- 优势：防止机器被无关(irrelevant)变量欺骗




arXiv:1704.06279 (cond-mat)

[Submitted on 20 Apr 2017 (v1), last revised 24 Sep 2018 (this version, v2)]

Mutual Information, Neural Networks Renormalization Group

Maciej Koch-Janusz, Zohar Ringel




Machine Learning Holographic Mapping by Neural Network Renormalization Group


H Hu, S-H Li, L Wang, Y-Z You. arXiv: 1903.00804



Hong-Ye Hu
(UCSD)



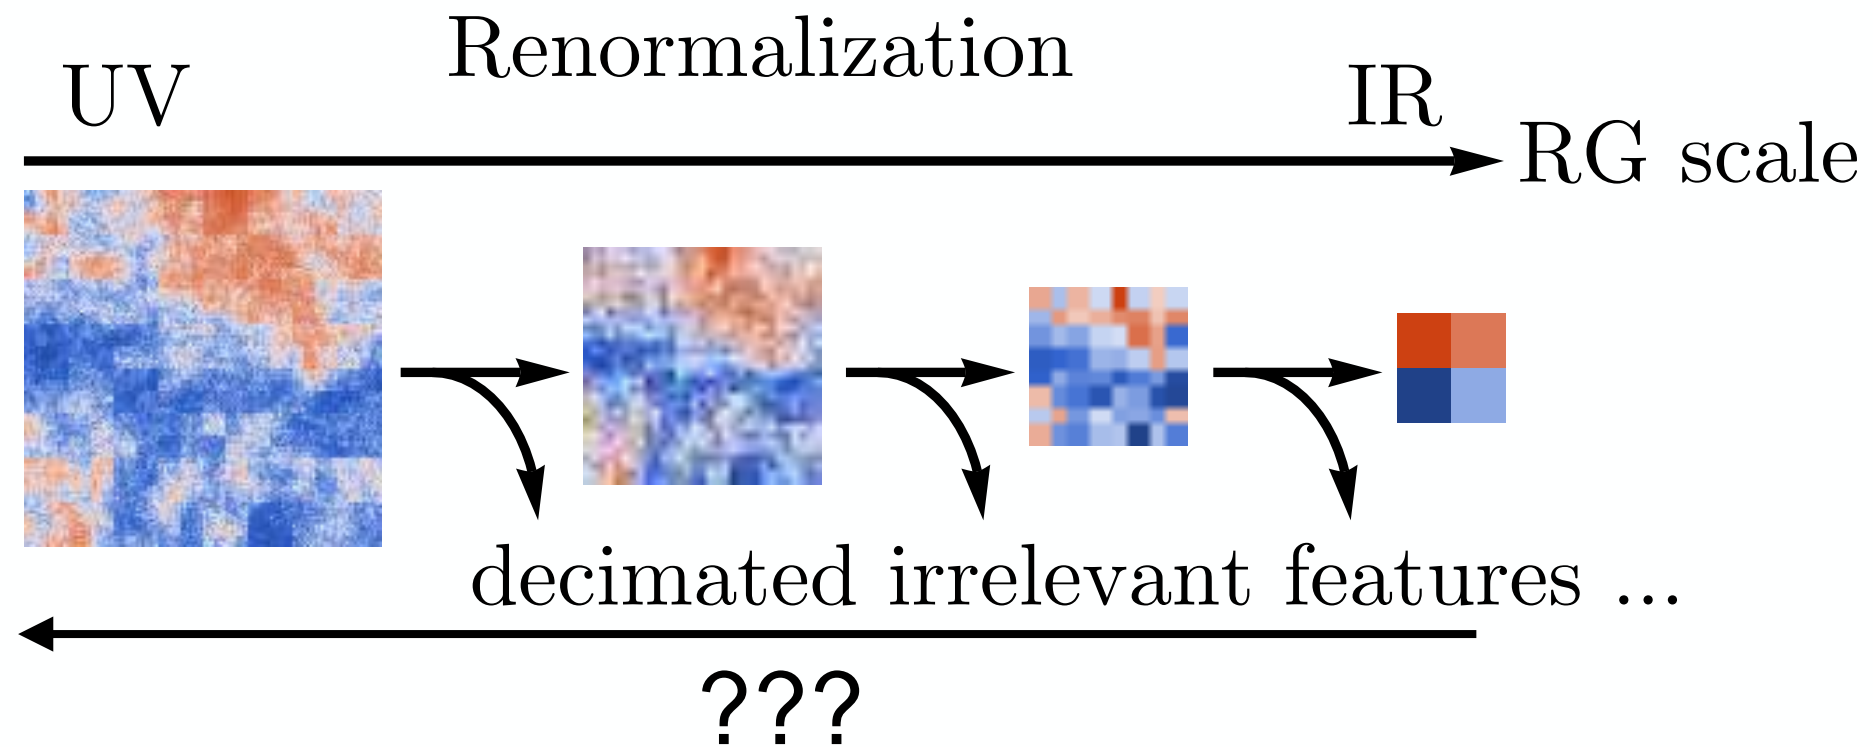
Shuo-Hui Li
(IOP, CAS)



Lei Wang

重整化与全息编码


- 传统意义上的重整化：不断地丢信息，不可逆，不成群



Traditional RG is not invertible...

重整化与全息编码

● 可逆计算




A	B	X
0	0	0
0	1	0
1	0	0
1	1	1

AND

A	B	X
0	0	0
0	1	1
1	0	1
1	1	1

OR



A	B	X	Y
0	0	0	0
0	1	0	1
1	0	1	1
1	1	1	0

CNOT

A	B	C	X	Y	Z
0	0	0	0	0	0
0	0	1	0	0	1
0	1	0	0	1	0
0	1	1	1	1	1
1	0	0	1	0	0
1	0	1	1	0	1
1	1	0	1	1	0
1	1	1	0	1	1

Toffoli (CCNOT)

Universal

- 可逆计算可以没有熵产生，原则上消除计算机发热
- 可逆元件构成的计算线路/神经网络也是可逆的



R. Landauer

重整化与全息编码

- 传统重整化

- 压缩映射

- 提取相关变量，同时丢弃无关变量

- 目标：信息压缩

- 全息重整化

- 可逆映射（编码-解码）

- 提取相关变量，同时保留无关变量

- 目标：全息编码

Renormalization

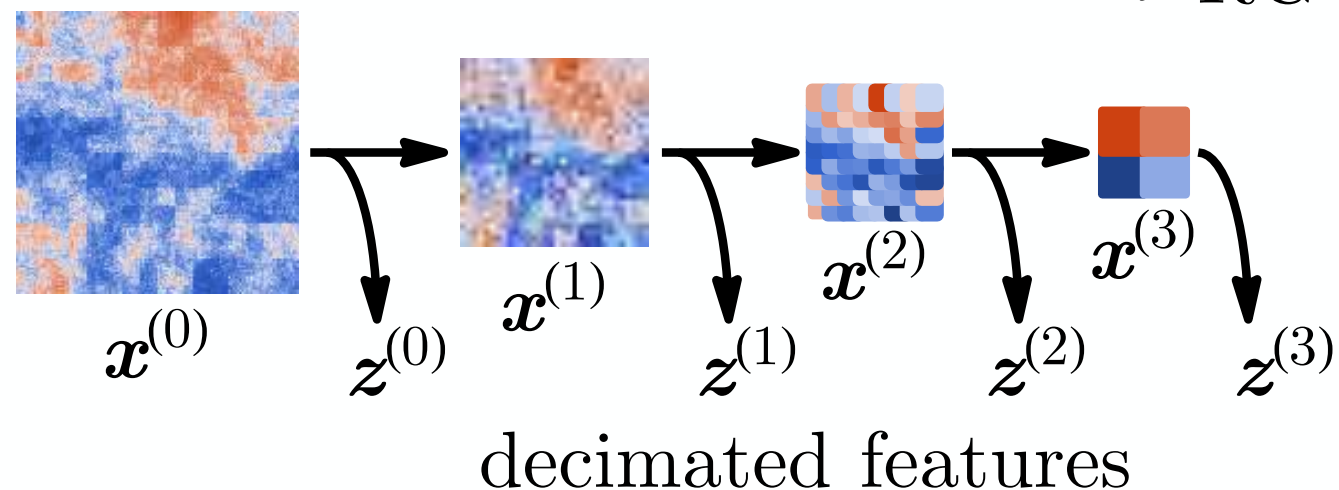
全息重整化变换

$$\begin{array}{c} \mathbf{x}^{(h+1)}, \mathbf{z}^{(h)} = R_h(\mathbf{x}^{(h)}) \\ \uparrow \qquad \qquad \uparrow \qquad \qquad \uparrow \\ \text{相关变量} \quad \text{无关变量} \quad \text{由可逆元件构成的可逆神经网络} \end{array}$$

Fine-grained

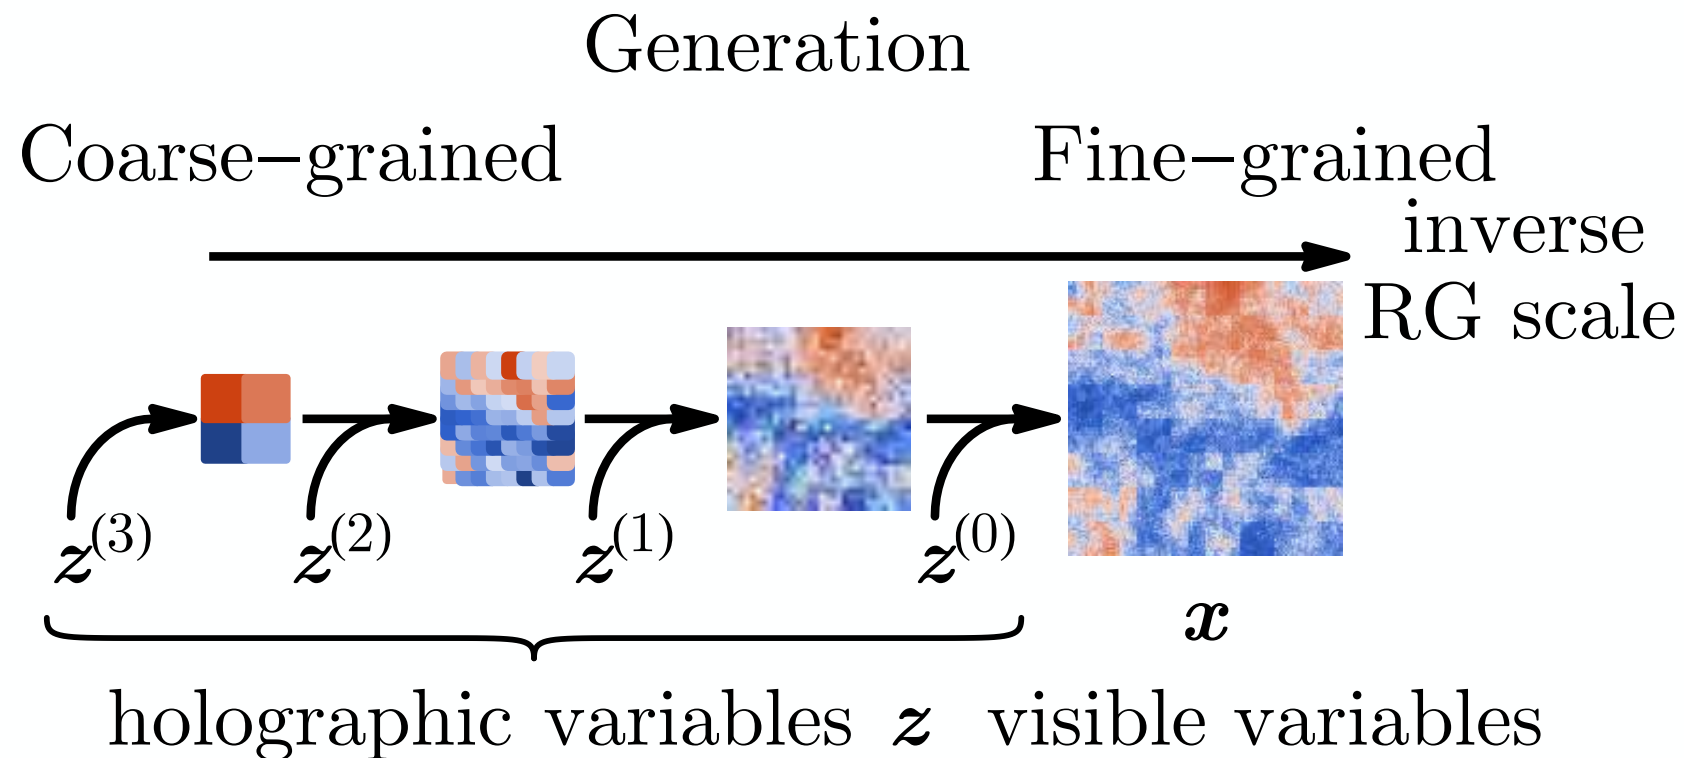
Coarse-grained

RG scale



重整化与全息编码

- 不压缩信息还要重整化什么用？ - 考虑问题不要太急功近利
- **Generation (生成) ← inverse → Renormalization (重整)**



$$x^{(h)} = R_h^{-1}(x^{(h+1)}, z^{(h)}) = G_h(x^{(h+1)}, z^{(h)})$$

逆重整化迭代 → 生成型模型的生成映射

$$x \equiv x^{(0)} = G_0(G_1(G_2(\cdots, z^{(2)}), z^{(1)}), z^{(0)}) \equiv G(z)$$

重整化与全息编码

- 流基生成型模型(Flow-Based Generative Model)

- 概率模型：生成映射诱导概率分布的变换

$$P_{\text{mdl}}(\mathbf{x}) = P_{\text{prior}}(\mathbf{z}) \det \left(\frac{\partial G(\mathbf{z})}{\partial \mathbf{z}} \right)^{-1}$$

- 目标概率： $P_{\text{tgt}}(\mathbf{x}) = Z^{-1} e^{-H(\mathbf{x})}$ (来自于物理模型)

- 优化目标：最小化KL散度

$$D_{KL}(P_{\text{mdl}} || P_{\text{tgt}}) = \mathbb{E}_{\mathbf{x} \sim P_{\text{mdl}}} (H(\mathbf{x}) + \ln P_{\text{mdl}}(\mathbf{x})) + \text{const.}$$

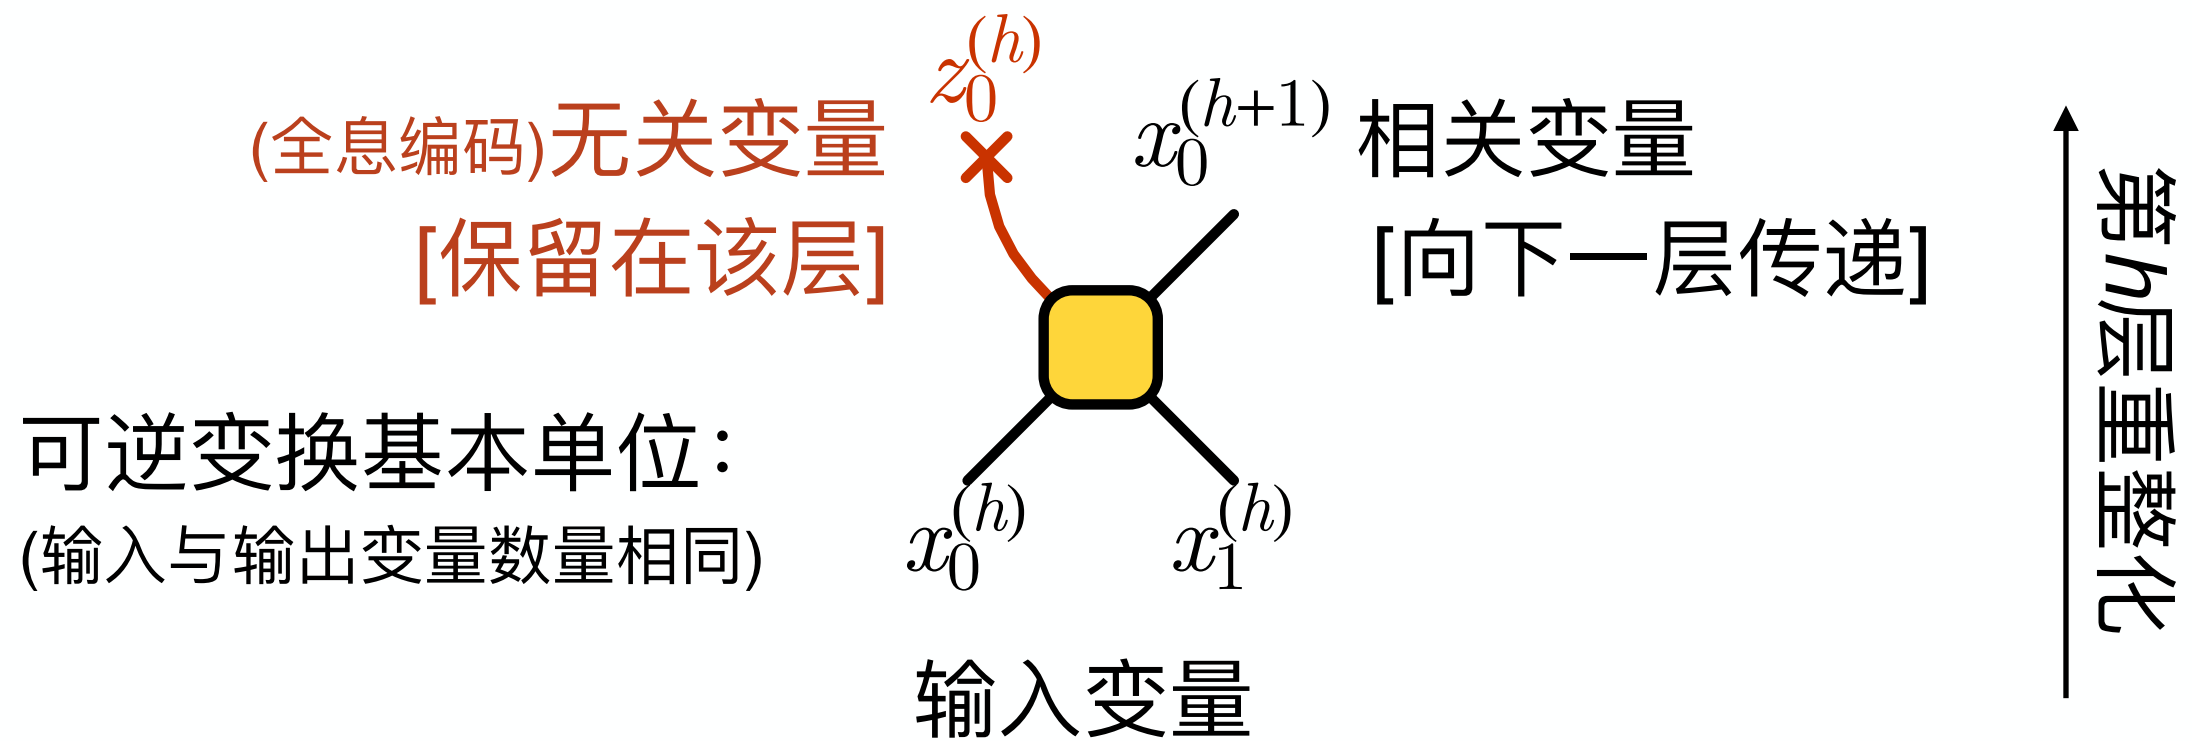
- 优化变量：生成映射 G (亦或重整映射 $R = G^{-1}$) 中的参数

- 训练后可获得对物理模型 H 的最优重整化方案 R

- 待定问题：如何选择 $P_{\text{prior}}(\mathbf{z})$? - 最小全息互信息原理

最小全息互信息原理



- 全息重整化由许多局部的可逆变换组成



$$x_i^{(h+1)}, z_i^{(h)} = R_h(x_{2i}^{(h)}, x_{2i+1}^{(h)}) \quad (\text{局部变换})$$


最小全息互信息原理

- 全息重整化由许多局部的可逆变换组成



最小全息互信息原理

- 最小全息互信息原理：无关变量(全息编码)之间应相互独立



$$I(z_A^{(h)} : z_B^{(h)}) =$$

$$\mathbb{E}_{z \sim P_{\text{prior}}} \ln \frac{P_{\text{prior}}(z_A, z_B)}{P_{\text{prior}}(z_A) P_{\text{prior}}(z_B)}$$

最小全息互信息

最大环境互信息

$$\min I(z_A^{(h)} : z_B^{(h)}) \Rightarrow \max I(x_A^{(h+1)} : x_B^{(h+1)})$$

(在相同层级内)

- 除了同层级内解耦，亦要求层级间解耦
- 可通过设定 $P_{\text{prior}}(z)$ 在模型上直接满足 (不用与KL散度竞争)

$$P_{\text{prior}}(z) = \prod_{i,h} P_{\text{prior}}(z_i^{(h)})$$

RG-Flow: A hierarchical and explainable flow model

H Hu, D Wu, Y-Z You, B Olshausen, Y Chen. arXiv: 2010.00029



Hong-Ye Hu
(UCSD)



Dian Wu




Yubei Chen
(UC Berkeley)



Bruno Olshausen


Two Toy Multi-Scale Datasets

MSDS1



High-level: color
Low-level: orientation

MSDS2




High-level: orientation
Low-level: color


Multi-scale Latent Representation

- Tuning a low-level holographic variable

MSDS1 (Low-level: orient.)




MSDS2 (Low-level: color)



Multi-scale Latent Representation

- Tuning a high-level holographic variable




- How is it useful? - Global features are hard to learn.


Compare with Real NVP

MSDS1

RG-Flow
(Ours)




Real NVP




Compare with Real NVP

MSDS2

RG-Flow
(Ours)




Real NVP



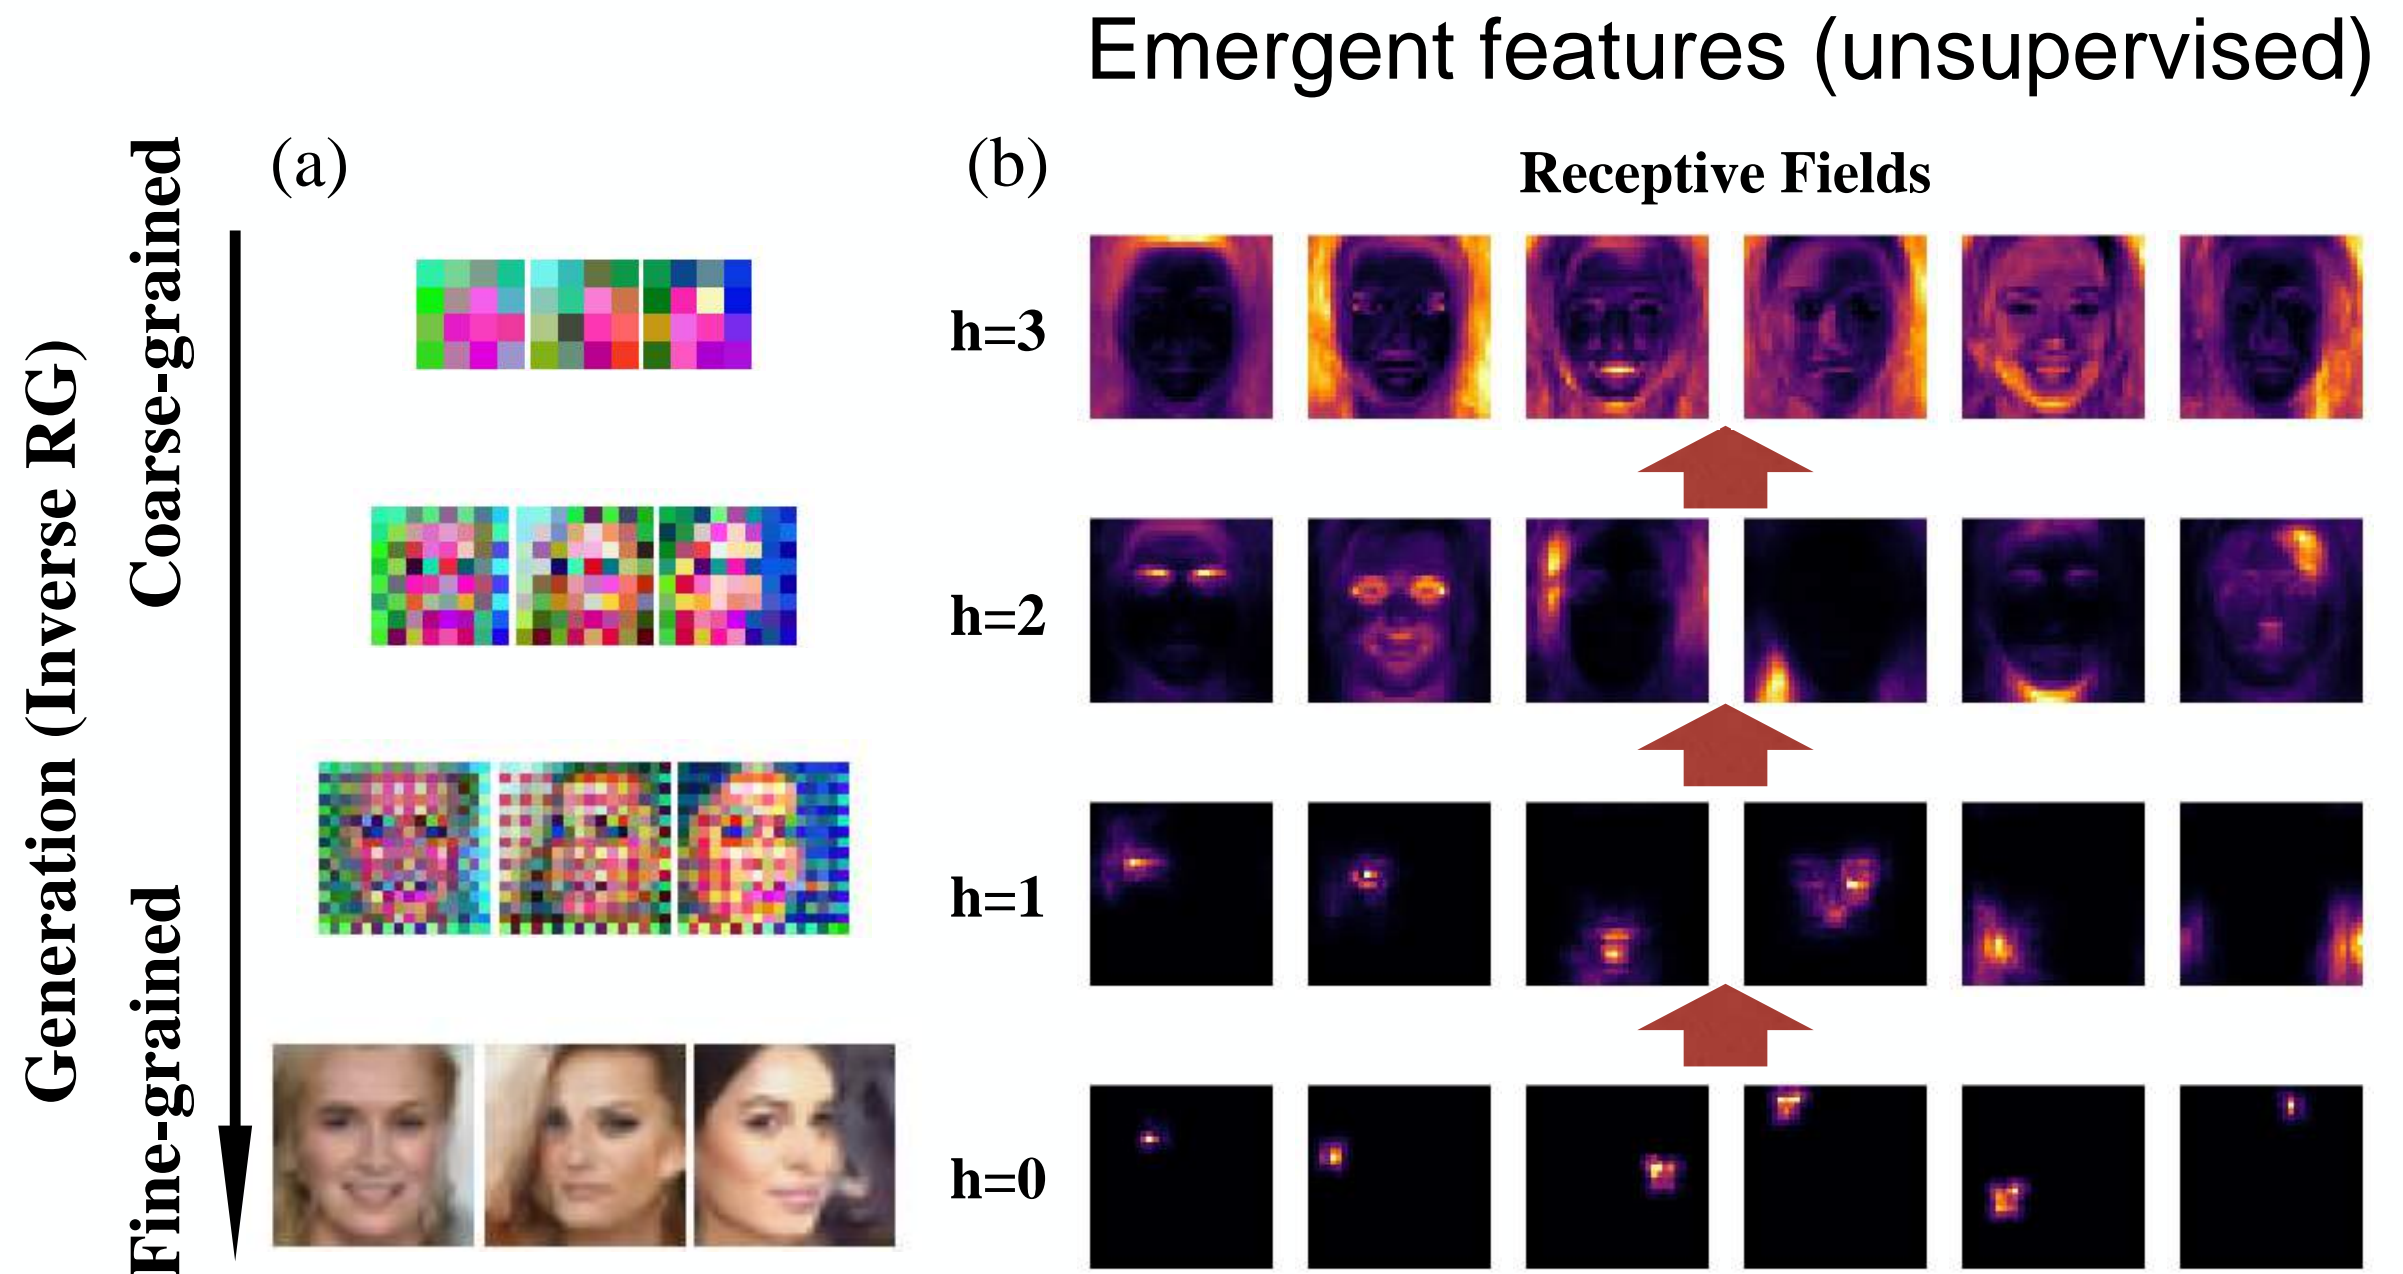
Human Face Dataset (CelebA)

- Samples generated by RG-Flow:




Emergent Hierarchical Representations

- After training, probe how visible variables respond to perturbations of holographic variables.



Emergent Hierarchical Representations

- Features at different scales



Gender



Emotion




Eye



High-level features




Mid-level features



Multi-Scale Feature Mixing

- Mixing high-level features of A with low-level features of B

$$z^{(h)} = \begin{cases} z_A^{(h)} & \text{for } h \geq h_c, \\ z_B^{(h)} & \text{for } h < h_c \end{cases}$$




Efficient Error Correction

- Error correction: restore locally corrupted images

RG-Flow
Constrained
Real NVP




- Past light-cone only covers $\sim O(\log N)$ volume in the hyperbolic space
- Only need to resample $\sim O(\log N)$ holographic variables to restore the corrupted image



全息对偶与量子引力

- 黑洞信息悖论：落入黑洞的信息消失了，违反量子力学要求的信息守恒（信息不生不灭，只能改变）
- 主流解释：三维物体落入黑洞后，其信息以量子编码形式呈现于黑洞的二维表面(视界)，这些信息会随黑洞蒸发而复现




Kurzgesagt – The Information Paradox

YouTube

全息对偶与量子引力

- 三维物体是如何被呈现于二维表面的？（二向箔？）
- 全息对偶：边界量子系统可以与体内的引力系统对应

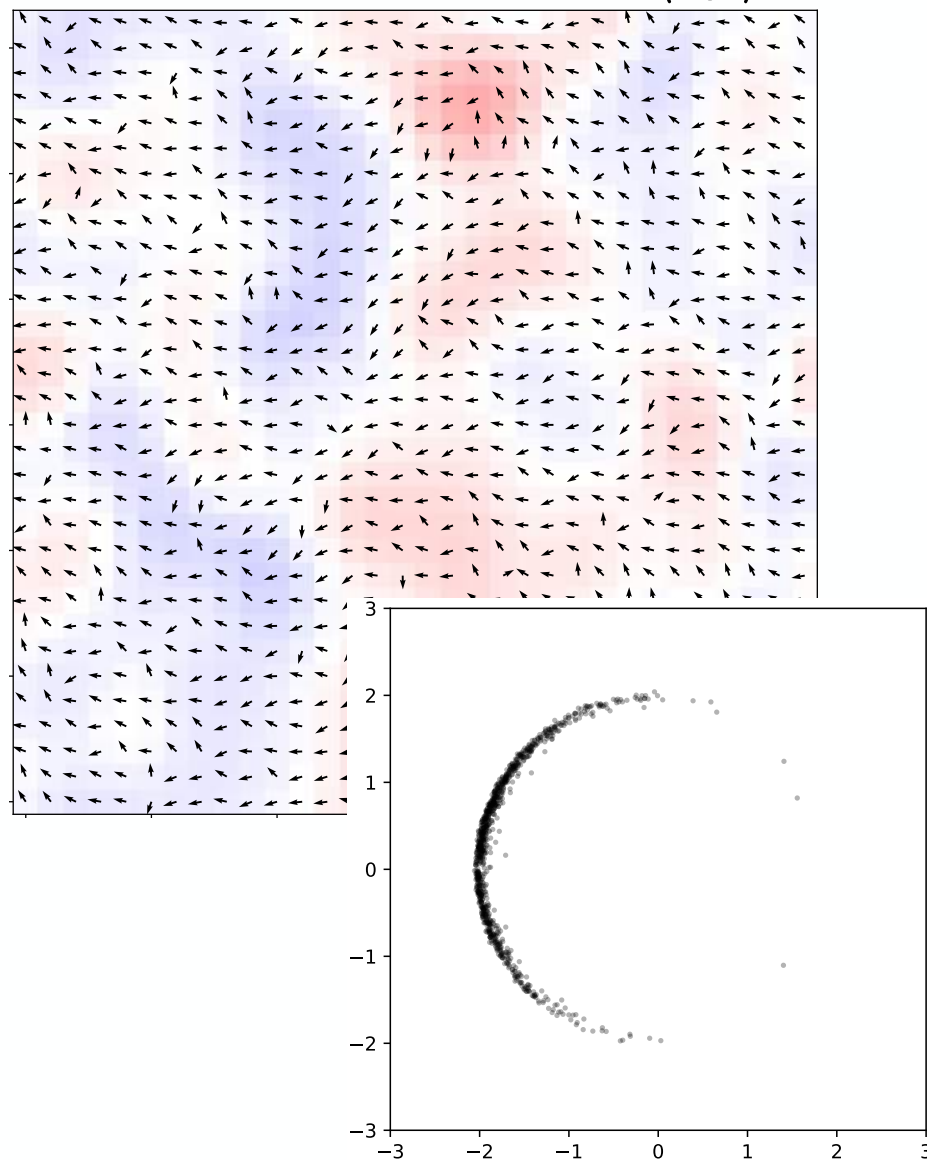


- 如何解码隐藏于量子纠缠中的时空几何？
 - 对量子场论进行全息重整化 → 全息对偶的时空结构

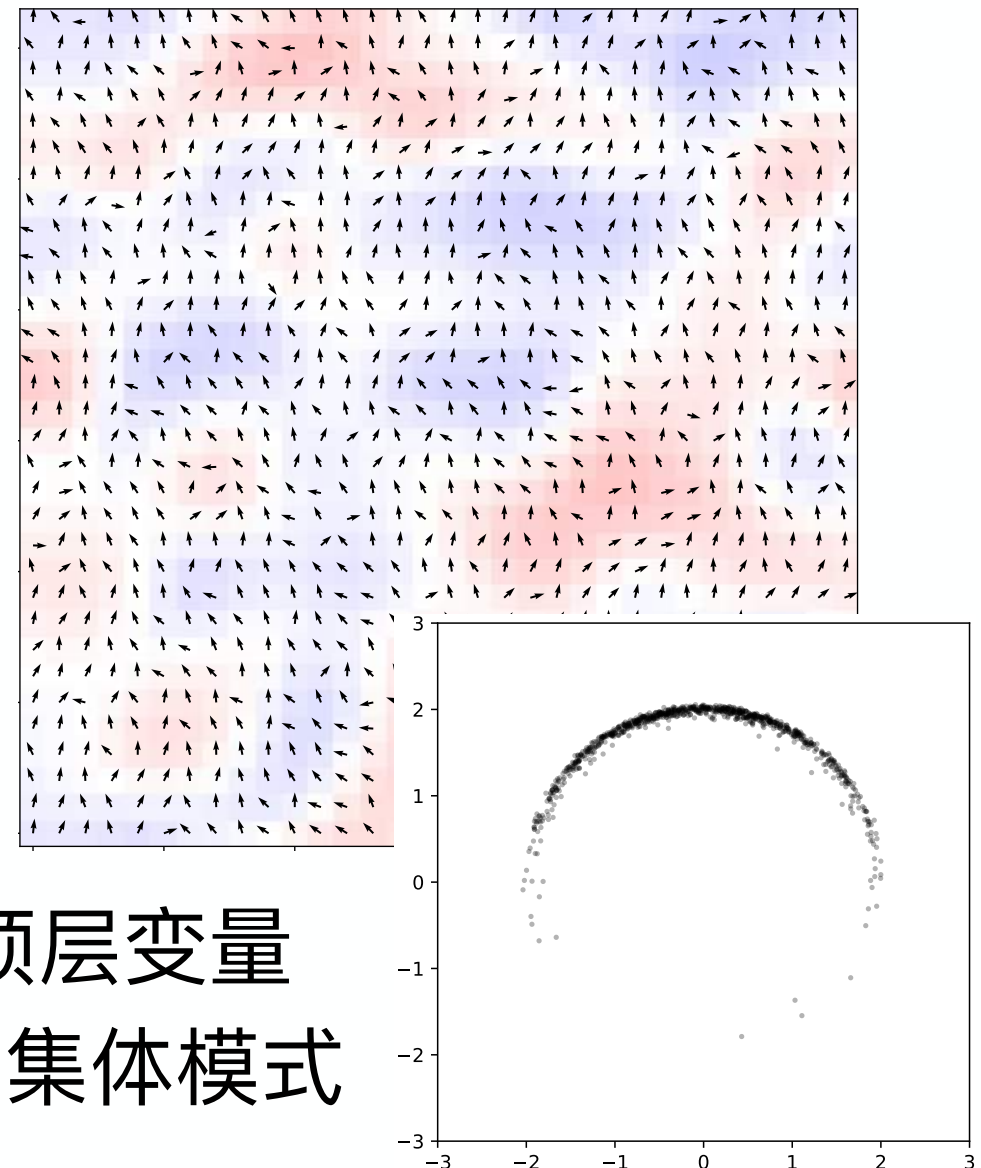
全息对偶与量子引力

- 2D复标量场的共形场论 (conformal field theory)

$$S[\phi] = -t \sum_{\langle ij \rangle} \phi_i^* \phi_j + \sum_i (\mu |\phi_i|^2 + \lambda |\phi_i|^4)$$




调整顶层变量
- 控制集体模式



全息对偶与量子引力

- 进一步研究全息变量之间的残余互信息



将量子场论的概率模型
送回经过训练的网络



$$P_{\text{post}}[\xi] = P_{\text{QFT}}[\phi] \det \left(\frac{\partial R[\phi]}{\partial \phi} \right)^{-1}$$

- 时空几何从互信息中涌现

$$d(a, b) = -\xi \ln \frac{I(\zeta(x_a, z_a) : \zeta(x_b, z_b))}{I_0}$$

$$d(x, y, z | x + r, y, z) \sim \ln r$$

$$d(x, y, z | x, y, z + r) \sim r$$



- 结果与双曲几何吻合

$$ds^2 = \frac{1}{z^2} (dx^2 + dy^2 + dz^2)$$